

Exercice 1:

Il que l'équation de la régression linéaire (HAR) suivante à l'aide de la représentation dual

$$J(\vec{w}) = \frac{1}{2} \sum_{n=1}^N (\vec{w}^T \phi(x_n) - t_n)^2 + \frac{\lambda}{2} \vec{w}^T \vec{w} \quad (1)$$

est donnée suivant l'équation: $y(x) = k(x)^T (k + \lambda I)^{-1} t = a^T \phi(x)$

Soit $J(\vec{w}) = \frac{1}{2} \sum_{n=1}^N (\vec{w}^T \phi(x_n) - t_n)^2 + \frac{\lambda}{2} \|\vec{w}\|^2$ (la solution à posteriori)

En prenant le gradient à 0.

$$\frac{\partial J(\vec{w})}{\partial \vec{w}} = 0 \Rightarrow \sum_{n=1}^N (\vec{w}^T \phi(x_n) - t_n) \phi(x_n) + \lambda \vec{w} = 0$$

$$\hookrightarrow \sum_{n=1}^N (\vec{w}^T \phi(x_n) - t_n) \phi(x_n) = -\lambda \vec{w}$$

$$\vec{w} = -\frac{1}{\lambda} \sum_{n=1}^N (\vec{w}^T \phi(x_n) - t_n) \phi(x_n) = -\sum_{n=1}^N \left(\frac{\vec{w}^T \phi(x_n) - t_n}{\lambda} \right) \phi(x_n)$$

On pose $a_n = -\frac{\vec{w}^T \phi(x_n) - t_n}{\lambda} \quad \forall n \in \{1, \dots, N\}$

$$\hookrightarrow \vec{w} = \sum_{n=1}^N a_n \phi(x_n) \Rightarrow \boxed{\vec{w} = \Phi^T \vec{a}} \quad (2) \quad \text{Lg } \phi = \begin{bmatrix} \phi(x_1) \\ \vdots \\ \phi(x_N) \end{bmatrix} \text{ et } \vec{a} = \begin{bmatrix} a_1 \\ \vdots \\ a_N \end{bmatrix}$$

De (1) et (2): $J(\vec{a}) = \frac{1}{2} [\vec{a}^T \Phi \Phi^T \vec{a} - 2 \vec{a}^T \Phi \vec{t} + \vec{t}^T \vec{t}] + [\frac{\lambda}{2} \vec{a}^T \Phi \Phi^T \vec{a}]$ (voir page suivante pour plus de détails)

En introduisant la notation de gramme $K = \Phi \Phi^T$ et $k(\vec{x}_n, \vec{x}_m) = \phi(\vec{x}_n)^T \phi(\vec{x}_m)$

$$K = \begin{pmatrix} k(\vec{x}_1, \vec{x}_1) & \dots & k(\vec{x}_1, \vec{x}_N) \\ \vdots & \ddots & \vdots \\ k(\vec{x}_N, \vec{x}_1) & \dots & k(\vec{x}_N, \vec{x}_N) \end{pmatrix} \quad \text{donc } J(\vec{a}) = \frac{1}{2} [\vec{a}^T K \vec{a}] - \vec{a}^T K \vec{t} + \frac{1}{2} \vec{t}^T \vec{t} + \frac{\lambda}{2} \vec{a}^T K \vec{a}$$

En prenant le gradient à 0 On aura: $\vec{\nabla} J(\vec{a}) = 0 \Rightarrow \frac{\lambda}{2} K \vec{a} + \lambda \vec{a} = K \vec{t}$

Pour la prédiction d'une entrée \vec{x} donné On applique les fct de base à chaque donnée.

$$\text{Lg } \vec{x} \mapsto \phi(\vec{x}) \quad \forall \vec{x}$$

$$y_w(\vec{x}) = \vec{w}^T \phi(\vec{x}) = \vec{a}^T \Phi \phi(\vec{x}) = [(K + \lambda I_N)^{-1} \vec{t}]^T \Phi \phi(\vec{x})$$

$$= [[(K + \lambda I_N)^{-1} \vec{t}]^T \cdot \Phi \Phi^T \phi(\vec{x})]^T \in \mathbb{R} \quad (y_w(\vec{x}) = y_w^T(\vec{x}))$$

$$= [(K + \lambda I_N)^{-1} \vec{t}]^T (\Phi \Phi^T \phi(\vec{x}))^T$$

Or $(\Phi \cdot \phi(\vec{x}))^T = [\phi(\vec{x}_1)]^T \cdot \phi$ et $\phi^T = (\phi(x_1), \phi(x_2), \dots, \phi(x_N))$

$$= [\phi(\vec{x})]^T (\phi(x_1), \dots, \phi(x_N))$$

$$= (\phi(x_1), \dots, \phi(x_N)) [\phi(\vec{x})]^T$$

$$= (\phi(x_1) \phi^T(\vec{x}), \dots, \phi(x_N) \phi^T(\vec{x}))$$

$$= K^T(\vec{x})^T$$

$$\hookrightarrow \boxed{y_w(\vec{x}) = K^T(\vec{x}) (K + \lambda I_N)^{-1} \vec{t}} \quad \text{Lg } K(\vec{x}) = \begin{pmatrix} k(\vec{x}_1, \vec{x}) \\ \vdots \\ k(\vec{x}_N, \vec{x}) \end{pmatrix}$$

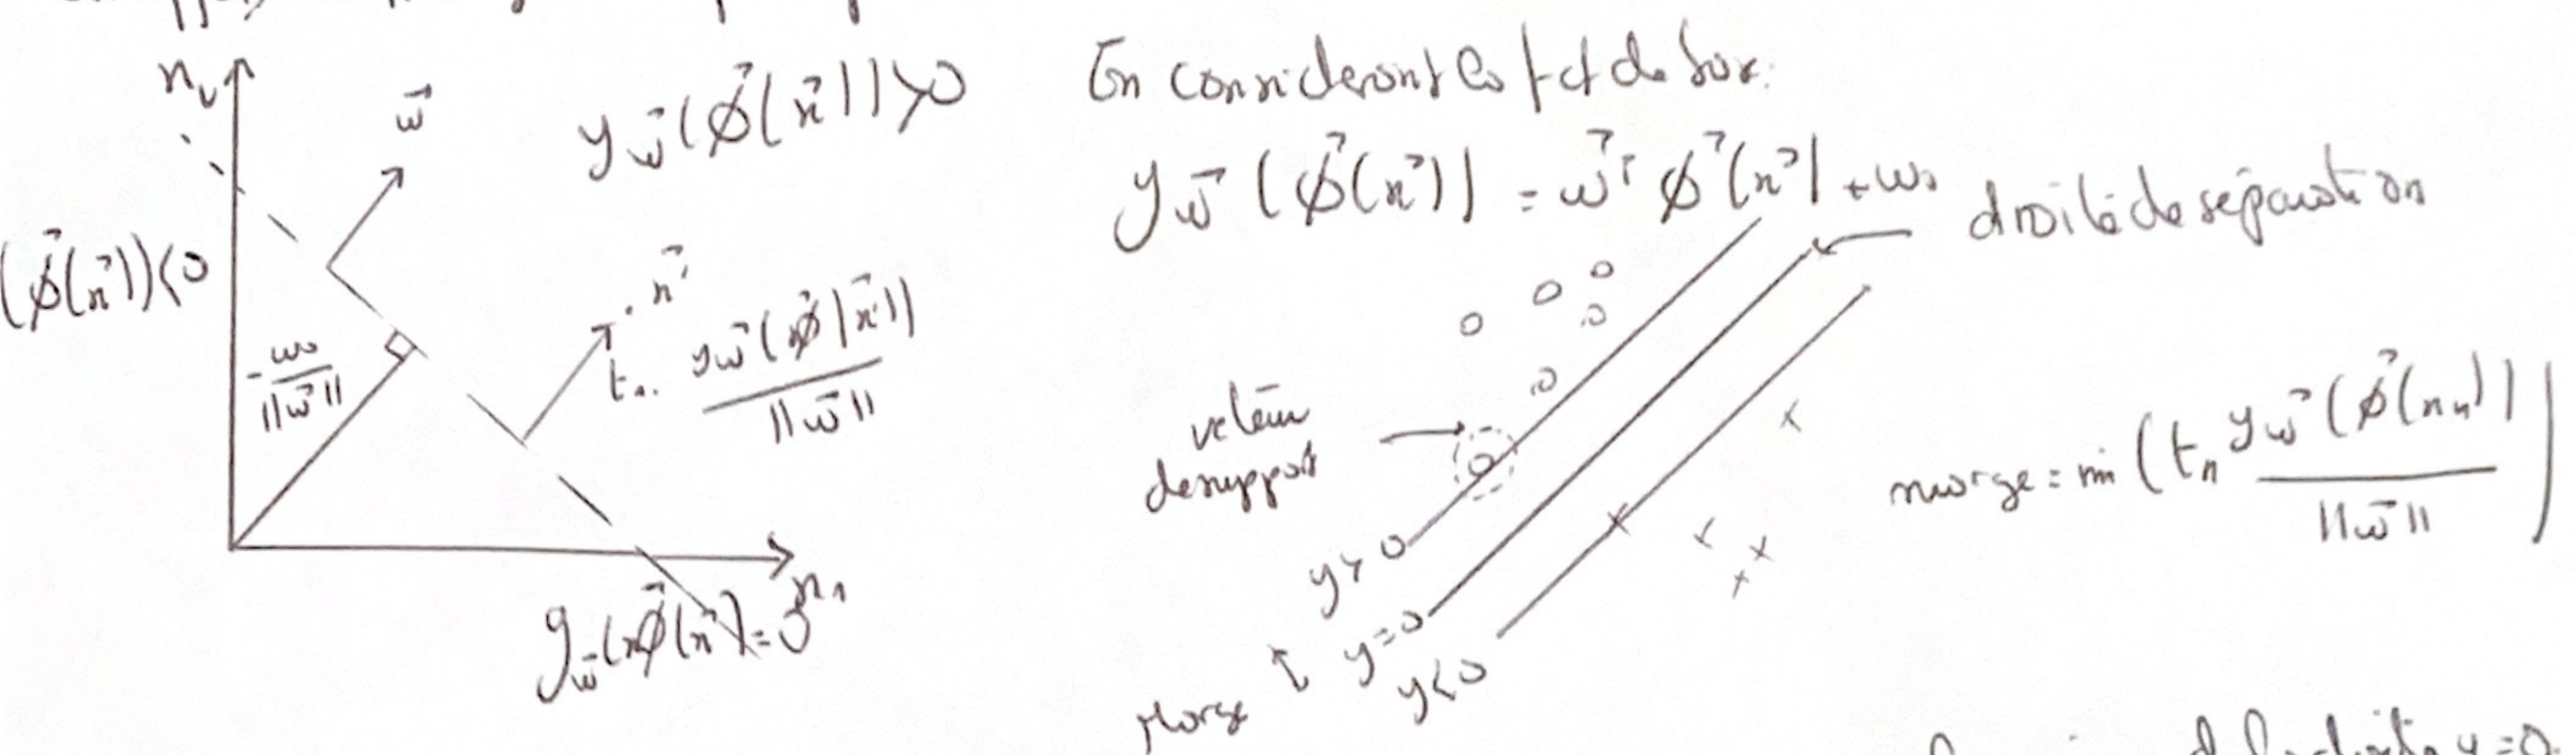
$$\text{Def 2} \quad \left\{ \begin{array}{l} J(\vec{\omega}) = \frac{1}{2} \sum_{n=1}^N (\vec{\omega}^T \phi(x_n) - t_n)^2 + \frac{\lambda}{2} \vec{\omega}^T \vec{\omega} \\ \vec{\omega} = \phi^T a \end{array} \right.$$

$$\begin{aligned} J(\vec{\omega}) &= \frac{1}{2} \sum_{n=1}^N (a^T \phi \phi(x_n) - t_n)^2 + \frac{\lambda}{2} a^T \phi \phi^T a \\ &= \frac{1}{2} \sum_{n=1}^N \left((a^T \phi \cdot \phi(x_n))^2 - 2 a^T \phi \cdot \phi(x_n) t_n + t_n^2 \right) + \frac{\lambda}{2} a^T \phi \phi^T a \\ &= \frac{1}{2} \sum_{n=1}^N a^T \phi \cdot \phi(x_n) \times a^T \phi \cdot \phi(x_n) - \sum_{n=1}^N a^T \phi \cdot \phi(x_n) t_n + \frac{1}{2} \sum_{n=1}^N t_n \cdot t_n \\ &\quad + \frac{\lambda}{2} a^T \phi \phi^T a \\ &= \frac{1}{2} a^T \phi \phi^T \phi \phi^T a - a^T \phi \phi^T t + \frac{1}{2} t^T t + \frac{\lambda}{2} a^T \phi \phi^T a \end{aligned}$$

On pose $K = \phi \phi^T$

$$\Rightarrow J(a) = \frac{1}{2} a^T K K a - a^T K t + \frac{1}{2} t^T t + \frac{\lambda}{2} a^T K a.$$

Exo 2:
 Avant d'expliquer les vecteurs de support il est primordial d'aborder la notion de marge.
 En effet, la marge est la plus petite distance entre la surface de séparation et les données d'entraînement.



Les vecteurs support alors sont les points qui tombent sur la marge qui leur sépare des autres $y=0$.
 En utilisant une approche avec la méthode des moindres carrés on a la prédiction

$$(*) \quad y(\vec{n}) = \sum_{n=1}^N a_n t_n k(\vec{x}_n, \vec{x}) + w_0 \quad (\text{approche duale})$$

avec $t_n \in \{-1, 1\}$ (En fonction de $k(\vec{x}_n, \vec{x})$ notation de gram et a_n optimisés avec l'entraînement)

Pour chercher les paramètres et hyperplan (\vec{w}, w_0) qui maximise la marge on utilise SVM b.

$$\arg \max_{\vec{w}, w_0} \{marge(\vec{w}, w_0)\} = \arg \max_{\vec{w}, w_0} \left\{ \min_n \left(t_n \frac{y \vec{w}(\phi(\vec{n}))}{\|\vec{w}\|} \right) \right\}$$

$$= \arg \max_{\vec{w}, w_0} \left\{ \frac{1}{\|\vec{w}\|} \min_n \left(t_n (\vec{w}^T \phi(\vec{n}) + w_0) \right) \right\}$$

Il y a une infinité de solutions à ce problème.

donc par qu'on considère une contrainte sur les vecteurs support t_n :

$$t_n y \vec{w}(\phi(\vec{n})) = t_n (\vec{w}^T \phi(\vec{n}) + w_0) = 1$$

par l'approche duale (*) seuls les vecteurs support vont figurer dans

$$\text{l'équation sous contrainte: } \begin{cases} t_n y(\vec{x}_n) = 1 \text{ et } a_n > 0 \\ t_n y(\vec{x}_n) > 1 \text{ et } a_n = 0. \end{cases}$$

Or lorsque les données sont non séparables on doit introduire les variables de relâchement

$\{ \eta_n \}$ qui correspondent aux violations des contraintes de marge.

si η_n est plus grande que 1 : $\eta_n > 1$ la donnée \vec{x}_n est mal classée.

$$\arg \min_{\vec{w}, w_0, \eta} \left\{ \frac{1}{2} \|\vec{w}\|^2 \right\} + C \sum_{n=1}^N \eta_n \quad \text{s.t. } t_n y_n (\vec{w}^T \phi(\vec{n})) \geq 1 - \eta_n \quad \forall n, \eta_n \geq 0$$

En tenant compte de la représentation duale.

$$\vec{\alpha}(\vec{x}) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m k(\vec{x}_n, \vec{x}_m) \quad \text{s.t. } \begin{cases} C \geq a_n \geq 0 \\ \sum_{n=1}^N a_n t_n = 0 \end{cases}$$

En tenant compte de la représentation primale.

$$\arg \min_{\vec{w}, w_0, \eta} \left\{ \frac{1}{2} \|\vec{w}\|^2 \right\} + C \sum_{n=1}^N \eta_n \quad \text{s.t. } t_n y_n (\vec{w}^T \phi(\vec{n})) \geq 1 - \eta_n \quad \forall n, \eta_n \geq 0$$

$$\Rightarrow \eta_n \geq 1 - t_n y_n \vec{w}^T \phi(\vec{n})$$

$$\arg \min_{\vec{w}, w_0} \frac{1}{2} \|\vec{w}\|^2 + C \sum_{n=1}^N \max(0, 1 - t_n y_n \vec{w}^T \phi(\vec{n}))$$

termes de régularisation notion de marge (fonction de perte (Hinge loss))

On retrouve ainsi une fct de perte de type Hinge loss avec un terme de régularisation.